Classification de la localisation de tumeurs cérébrales pédiatriques

Intégration multi-omique (expression génique + CGH) en régime $p \gg n$

R. Barata A. De Rouck M. Hoizey-Cangioloni P. Lubaszewski Lima M. Seyedi

CentraleSupélec

Encadrant : Arthur Tenenhaus

juin 2026

Plan de la présentation

1. Introduction et problématique
2. Analyse exploratoire (EDA)
3. Formalisme et méthodes
4. Résultats
5. Stabilité et reproductibilité
6. Travail bibliographique

Plan

1. Introduction et problématique
2. Analyse exploratoire (EDA)
3. Formalisme et méthodes
4. Résultats
5. Stabilité et reproductibilité
6. Travail bibliographique

Contexte clinique et problématique

Le problème

Prédire la **localisation anatomique** d'un gliome pédiatrique à partir de la seule **signature moléculaire** de la tumeur. La localisation conditionne fortement la résécabilité chirurgicale, le protocole de radiothérapie et le pronostic.

Trois localisations, donc trois classes :

- **cort** : tumeurs corticales / hémisphériques ;
- **dipg** : gliome pontique intrinsèque diffus, situé dans le pont de Varole (inopérable, pronostic très défavorable) ;
- **midl** : tumeurs de la ligne médiane, hors du pont (**classe rare**).

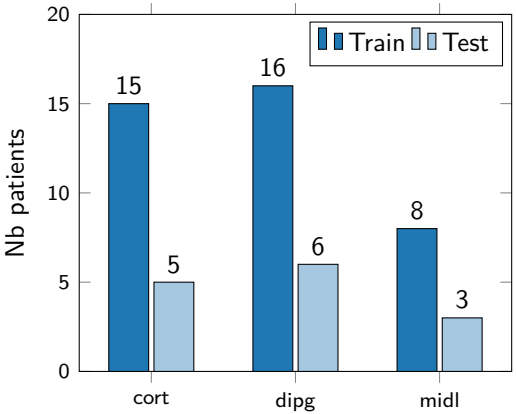
Le jeu de données

Deux blocs moléculaires :

- **GE** : expression génique : **15 702** variables (signal discriminant principal) ;
- **CGH** : gains / pertes chromosomiques : **1 229** variables (signal faible isolément).

Effectifs : $n = 53$ patients, soit **39** en entraînement et **14** en test.

	cort	**dipg**	**midl**
Train	15	16	8
Test	5	6	3



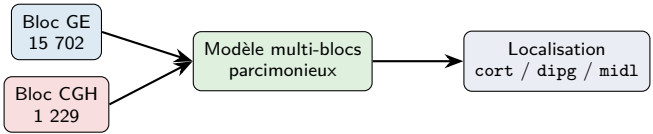
Répartition des classes : midl nettement minoritaire.

Le défi statistique : trois verrous

1. **Régime $p \gg n$ extrême** : $p = 16\,931$ variables pour $n = 39$ patients, soit $\frac{p}{n} \simeq 434$. La matrice de Gram $X^\top X$ est de rang $\leq n - 1 = 38$, donc *massivement singulière* : tout estimateur non régularisé est non identifiable.
2. **Deux blocs hétérogènes et déséquilibrés** : GE concentre 92,7 % des variables ; la fusion doit éviter de marginaliser CGH.
3. **Classe rare midl** : 8 patients en train, 3 en test. Chaque erreur déplace son rappel par pas de $1/3 \simeq 0{,}33$.

Réponses méthodologiques

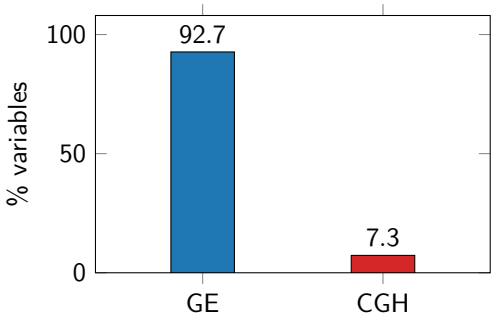
- Régularisation ℓ_1/ℓ_2 + sélection parcimonieuse ;
- mise à l'échelle par bloc + projection supervisée (SGCCA) ;
- pondération de la vraisemblance + **balanced accuracy**.



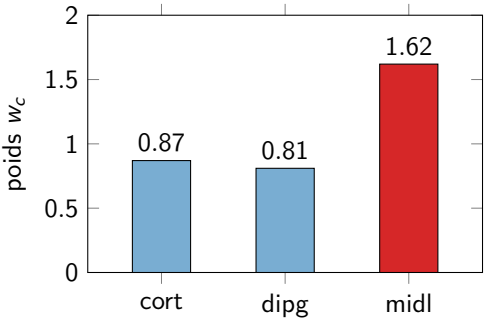
Plan

1. Introduction et problématique
2. Analyse exploratoire (EDA)
3. Formalisme et méthodes
4. Résultats
5. Stabilité et reproductibilité
6. Travail bibliographique

Domination du bloc GE et pondération des classes

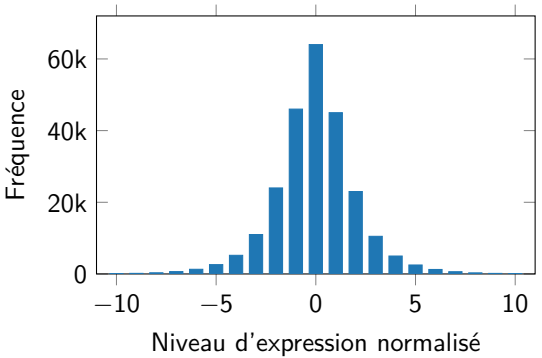


Inertie $\propto$ nombre de variables : la concaténation brute est dominée à $> 90\%$ par GE.



Poids inverses de prévalence $w_c = n/(K\, n_c)$: un patient midl pèse $\simeq 1{,}6\times$ un patient moyen.

Qualité des données : niveaux d'expression GE déjà normalisés

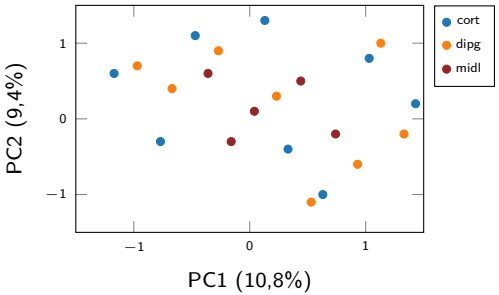


Distribution globale des $39 \times 15\,702$ valeurs d'expression :

- quasi symétrique, centrée (médiane = 0,03), bornée ($-10{,}43$ à $9{,}87$) ;
- données déjà normalisées (log-ratios) $\Rightarrow$ aucune transformation (log, Box-Cox), une simple standardisation z-score suffit.

Imputation par la médiane du train (reportée au test) : robuste aux valeurs extrêmes, sans fuite d'information.

La PCA non supervisée ne sépare pas les classes



- PC1+PC2 ne capturent que $\simeq 20\%$ de l'inertie pour GE ($\simeq 27\%$ pour CGH) ;
- les trois nuages se **chevauchent fortement** ; `midl` ne forme *aucun amas distinct*.

Conséquence

Une réduction *non supervisée* (PCA, Sparse PCA) jette la variance dans des directions non discriminantes $\Rightarrow$ échec des pipelines Sparse PCA + LogReg. **Il faut une projection supervisée** (SGCCA).

Signal univarié réel mais peu robuste, et forte redondance

***t* de Welch univariés `midl` vs reste** (Welch car variances inégales, $n_{\text{midl}} = 8$) :

- **GE** : quelques gènes à $|t| \simeq 4$–5 (p.ex. `A_32_P85999`) $\Rightarrow$ un signal univarié existe ;
- **CGH** : statistiques plafonnant vers $|t| \simeq 3$, signal plus faible.

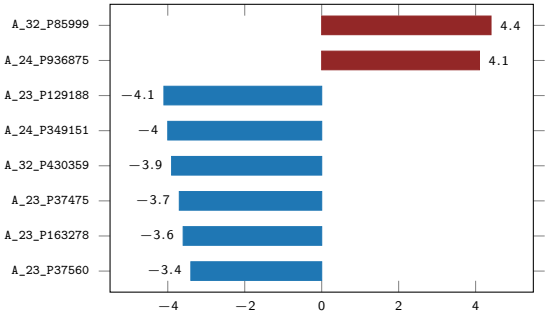
Forte redondance intra-bloc (groupes de variables corrélées, surtout CGH) :

- justifie la pénalisation **Elastic-Net**

Univarié $\neq$ multivarié robuste

Avec $p \gg n$ et $n_{\text{midl}} = 8$, ces t-statistiques sont elles-mêmes très bruitées (un patient peut faire basculer le classement) et ne contrôlent **pas** la multiplicité ($\sim 17\,000$ tests). Diagnostic exploratoire, pas une sélection valide $\Rightarrow$ sélection confiée à des méthodes pénalisées *intra-CV*.

Signal univarié autour de `midl` : top variables (t de Welch)



t de Welch (`midl` vs reste)

- **GE** : quelques gènes atteignent $|t| \simeq 4$–5 ; rouge = sur-exprimé chez `midl` (p.ex. `A_32_P85999`), la majorité y étant sous-exprimés ;
- **CGH** : statistiques plafonnant vers $|t| \simeq 3$, cohérent avec sa quasi-exclusion par les modèles parcimonieux.

Choix de la métrique : balanced accuracy

L'accuracy brute pondère implicitement par la fréquence et masquerait un échec sur `midl` (un classifieur ne prédisant jamais midl atteint déjà $\simeq 11/14$).

On retient le **macro-recall** (= balanced accuracy) :

$$\mathrm{BA}(\hat{f}) = \frac{1}{|\mathcal{Y}|} \sum_{c \in \mathcal{Y}} \underbrace{\frac{|\{i : Y_i = c, \hat{f}(X_i) = c\}|}{|\{i : Y_i = c\}|}}_{\mathrm{recall}_c}$$

même poids aux trois classes, indépendamment de la prévalence.

Un exemple

Pour un classifieur ne prédisant *jamais* `midl` :

$$\text{macro-recall} = \frac{1}{3}\left(\frac{5}{5} + \frac{6}{6} + \frac{0}{3}\right) = 0{,}667$$

Plan

1. Introduction et problématique
2. Analyse exploratoire (EDA)
3. Formalisme et méthodes
4. Résultats
5. Stabilité et reproductibilité
6. Travail bibliographique

Cadre probabiliste et classifieur de Bayes

Classification à 3 classes : (X_i, Y_i) i.i.d. $\sim P$, $X \in \mathbb{R}^p$, $Y \in \{1, 2, 3\}$. Risque d'un classifieur f pour une perte ℓ :

$$R(f) = \mathbb{E}_{(X,Y)\sim P}[\ell(f(X), Y)], \qquad f^\star = \arg\min_f R(f).$$

Sous la perte 0–1

Avec $\eta_c(x) = \mathbb{P}[Y = c \mid X = x]$, le prédicteur de Bayes est

$$f^\star(x) = \arg\max_{c \in \mathcal{Y}} \eta_c(x).$$

La 0–1 loss n'étant ni continue ni dérivable, on utilise une **perte de substitution** convexe et différentiable : l'entropie croisée.

Remarque : sous une perte *asymétrique* (pénaliser davantage l'erreur sur `midl`), le prédicteur de Bayes n'est plus l'argmax
des η_c : ce qui motive la pondération.

Régression logistique multinomiale

Modèle softmax (avec contrainte d'identifiabilité $\beta_3 = 0$) :

$$\eta_c^\beta(x) = \mathbb{P}_\beta[Y = c \mid X = x] = \frac{e^{\beta_c^\top x}}{\sum_{k=1}^{3} e^{\beta_k^\top x}}.$$

Maximiser la log-vraisemblance $\equiv$ minimiser l'**entropie croisée** empirique :

$$\hat{R}_n(\beta) = -\frac{1}{n}\sum_{i=1}^{n} \log \eta_{Y_i}^\beta(X_i), \qquad \nabla_{\beta_c} \hat{R}_n(\beta) = \frac{1}{n}\sum_{i=1}^{n} \left(\eta_c^\beta(X_i) - \mathbf{1}_{\{Y_i = c\}}\right) X_i.$$

- Objectif **convexe et différentiable** ; pas de solution analytique $\Rightarrow$ Méthode de Newton.
- Frontière de décision **linéaire** : $\hat{y} = \arg\max_c \hat{\beta}_c^\top x$.

Vraisemblance pondérée : poids inverses de prévalence

Le risque uniforme $\hat{R}_n$ est dominé par les classes majoritaires. On aligne l'objectif sur la balanced accuracy via

$$\hat{R}_n^w(\beta) = -\frac{1}{n}\sum_{i=1}^{n} w_{Y_i} \log \eta_{Y_i}^{\beta}(X_i).$$

Poids

Égaliser la contribution de chaque classe ($w_c n_c = \text{cte}$) puis normaliser ($\sum_c w_c n_c = n$) donne

$$w_c = \frac{n}{K\, n_c}, \qquad w_{\texttt{cort}} = 0{,}87, \quad w_{\texttt{dipg}} = 0{,}81, \quad w_{\texttt{midl}} = 1{,}62.$$

Le gradient pondéré amplifie d'un facteur $w_{\texttt{midl}}$ les résidus `midl`. Plus défendable qu'un sur-échantillonnage `SMOTE` (testé, peu concluant : fabriquer de faux patients en dimension 16 931 est instable). Le problème reste **convexe**.

Pénalisation Elastic-Net et cadre GLM

Elastic-Net pour contrôler la complexité en $p \gg n$:

$$\min_{\beta} \left\{ \hat{R}_n(\beta) + \lambda\rho\|\beta\|_1 + \frac{\lambda(1-\rho)}{2}\|\beta\|_2^2 \right\}$$

- ℓ_1 (Lasso) $\Rightarrow$ **sélection** de variables
- ℓ_2 (Ridge) $\Rightarrow$ **stabilité** face aux variables colinéaires
- ℓ_1 non différentiable $\Rightarrow$ optimisation proximale (soft-thresholding).

GLM

La régression logistique est le *GLM* canonique : $Y \mid X \sim$ loi catégorielle, lien logit, $g(\mu_i) = x_i^\top \beta$. La log-vraisemblance est concave $\Rightarrow$ l'EMV est unique et s'obtient par Newton (moindres carrés repondérés, IRLS).

Analyse Discriminante Linéaire (LDA)

Hypothèses : normalité conditionnelle $X \mid Y = c \sim \mathcal{N}_p(\mu_c, \Sigma)$ et **homoscédasticité** ($\Sigma_c = \Sigma$). La fonction discriminante se linéarise :

$$\delta_c(x) = \underbrace{(\Sigma^{-1}\mu_c)^\top}_{w_c^\top} x - \underbrace{\left(\tfrac{1}{2}\mu_c^\top \Sigma^{-1}\mu_c - \log \pi_c\right)}_{b_c}, \qquad f^\star(x) = \arg\max_c w_c^\top x - b_c.$$

Estimateurs : $\hat{\pi}_c = \frac{n_c}{n}$, $\hat{\mu}_c$ moyenne de classe, et covariance commune

$$\hat{\Sigma} = \frac{1}{n-K} \sum_c \sum_i (X_i - \hat{\mu}_c)(X_i - \hat{\mu}_c)^\top \mathbf{1}_{Y_i = c}.$$

Problème en $p \gg n$

$\hat{\Sigma}$ ($16\,931 \times 16\,931$) est **non inversible**. La LDA n'est donc pas appliquée sur les variables brutes mais sur les *composantes supervisées* issues de la SGCCA (quelques dimensions seulement).

Validation croisée : stratifiée, répétée, imbriquée

Avec $n = 39$, tout split unique est trop instable.

- **Stratification** : chaque pli préserve la prévalence des classes (sinon un pli peut ne contenir aucun `midl`) ;
- **Répétition** : $K \times R = 7 \times 3 = 21$ plis pour réduire la variance de $\hat{R}_{\text{CV}}$;
- **Métrique** : balanced accuracy optimisée et rapportée.

CV imbriquée (nested)

- *Boucle externe* : évalue $\hat{R}_{\text{CV}}$;
- *Boucle interne* : sélectionne $\hat{\lambda} = \arg\min_{\lambda} \hat{R}_{\text{int}}(\lambda)$ sur le seul fold-train.

$\Rightarrow \hat{\lambda}$ ne voit jamais les données d'évaluation : pas de **data leakage**. Toute sélection de variables se fait *à l'intérieur* des plis.

Fusion multibloc : des méthodes naïves au Cooperative Learning

Deux blocs : $X \in \mathbb{R}^{n \times p_{\text{GE}}}$ et $Z \in \mathbb{R}^{n \times p_{\text{CGH}}}$.

- **Early fusion** : concaténer $[X \mid Z] \Rightarrow$ GE domine, CGH marginalisé ;
- **Late fusion** : un modèle par bloc puis $\omega f_X + (1-\omega) f_Z \Rightarrow$ ignore les interactions inter-blocs.

Cooperative Learning (Ding & Tibshirani, PNAS 2022)

Interpolation continue entre les deux, via une **pénalité d'accord** $\rho \geq 0$ sur les logits :

$$J(\theta_x, \theta_z) = \hat{R}_{\text{CE}}(\theta_x, \theta_z) + \underbrace{\frac{\rho}{2} \|X\theta_x - Z\theta_z\|_F^2}_{\text{accord}} + P_{\text{Elastic-Net}}(\theta_x, \theta_z).$$

$\rho = 0$: early fusion ; $\rho \to \infty$: late fusion. Problème équivalent à un problème Elastic-Net sur les données *augmentées* $(\tilde{X}, \tilde{z})$.

SGCCA : la projection supervisée retenue

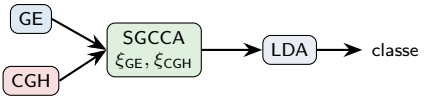
Sparse Generalized CCA (Tenenhaus *et al.*) : composantes parcimonieuses $y_j = X_j a_j$ maximisant la covariance *entre blocs connectés* :

$$\max_{a_1,\dots,a_J} \sum_{j,k} c_{jk}\, g\left(\mathrm{cov}(X_j a_j, X_k a_k)\right) \quad \text{s.c.} \quad \|a_j\|_2 \le 1,\ \|a_j\|_1 \le s_j.$$

- **3 blocs** : GE, CGH, et le bloc des *labels* Y comme **pivot supervisé** ;
- matrice de connexion : on corrèle chaque bloc moléculaire à Y, pas GE–CGH directement

$$C = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} ;$$

- budget $\ell_1 \Rightarrow$ sélection ; boule $\ell_2 \Rightarrow$ stabilité ;
- mise à l'échelle $\tilde{X}_j = X_j / \sqrt{p_j}$ pour égaliser l'inertie des blocs.



Les composantes alimentent une LDA dans un espace réduit, contournant la non-inversibilité de $\hat{\Sigma}$.

Plan

1. Introduction et problématique
2. Analyse exploratoire (EDA)
3. Formalisme et méthodes
4. Résultats
5. Stabilité et reproductibilité
6. Travail bibliographique

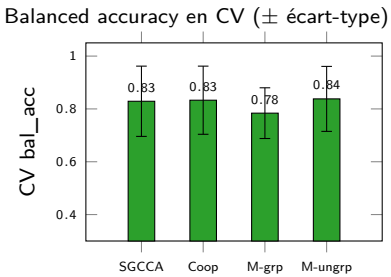
Sélection de variables et comparaison des pipelines

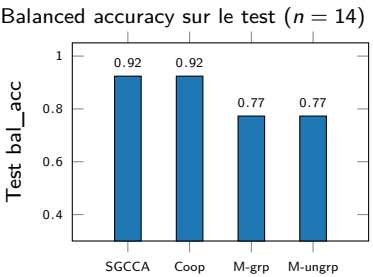
Quatre pipelines sparses supervisés, même protocole (CV stratifiée $7 \times 3 = 21$ plis, balanced accuracy, test $n = 14$ tenu à part). SGCCA retient **68 GE + 11 CGH** ($s_1 = 0{,}051$, $s_2 = 0{,}067$).

Méthode	**CV bal_acc**	**Test bal_acc**	`midl` **test**	**N vars**
Multinomial Lasso *grouped*	0,784 ± 0,096	0,773	0/3	27 GE
Multinomial Lasso *ungrouped*	0,838 ± 0,123	0,773	0/3	27 GE
Cooperative Lasso OvR ($\rho = 0$)	0,833 ± 0,129	0,924	2/3	42 GE
SGCCA + LDA	0,829 ± 0,133	0,924	2/3	68 GE + 11 CGH

- Seuls les pipelines *One-vs-Rest* ou à *espace latent supervisé* récupèrent `midl` (2/3) ;
- passer la pénalité ℓ_1 *grouped* $\rightarrow$ *ungrouped* fait gagner +0,054 en CV (au seul prix d'un argument) mais rien sur le test.

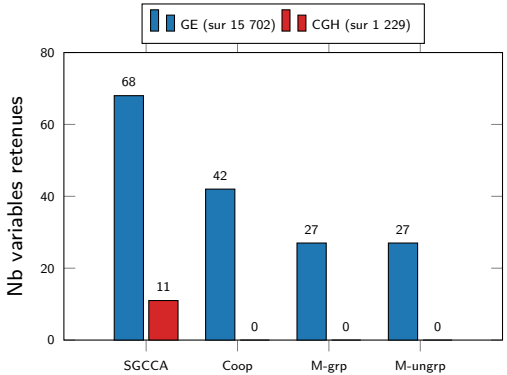
Performance comparée





En CV, trois méthodes plafonnent à $\simeq 0{,}83$; sur le test, seules **SGCCA + LDA** et **Cooperative OvR** atteignent 0,924.

Parcimonie effective : combien de variables par bloc ?



Toutes les méthodes *data-driven* excluent spontanément l'intégralité du bloc CGH.

Seule la **SGCCA** en conserve 11 variables : et uniquement parce que la contrainte de parcimonie s_{CGH} est imposée structurellement bloc par bloc.

Modèles très parcimonieux et interprétables (≤ 68 variables sur $\sim 17\,000$).

Le Cooperative Learning : une instabilité instructive

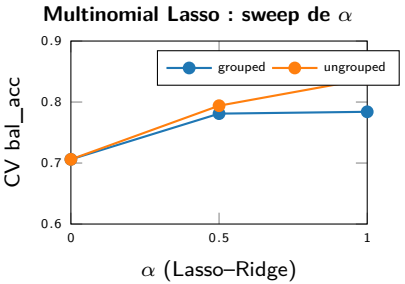
Avec `multiview` (sur `glmnet`), l'algorithme **diverge pour tout** $\rho > 0$ en formulation OvR (`algorithm did not converge`). Deux causes :

- les poids de Newton $w_i = \hat{p}_i(1 - \hat{p}_i) \to 0$ sur la classe rare $\Rightarrow X^\top W X$ quasi-singulière ;
- l'accord ajoute $\rho X^\top X$ et amplifie d'un facteur $(1 + \rho)$ des corrélations intra-bloc déjà extrêmes.

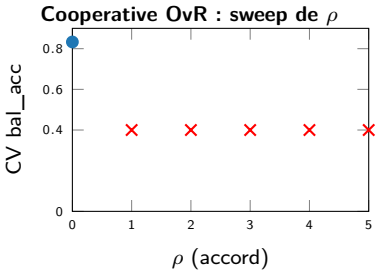
Lecture structurelle

La pénalité ℓ_1 pousse à *annuler* des coefficients tandis que l'accord pousse à *coupler* les vues : forces contradictoires quand GE et CGH ne partagent pas de signal commun fort. Seul $\rho = 0$ est exploitable (la méthode dégénère en Lasso OvR). La formulation *multinomiale* converge ($\rho^\star = 0{,}10$) mais à balanced accuracy plus basse.

Sensibilité aux hyperparamètres



À $\alpha = 1$, passer *grouped* $\rightarrow$ *ungrouped* : $+0{,}054$.



Croix rouges : non-convergence du solveur (`multiview/glmnet`) ;
seul $\rho = 0$ exploitable.

Multinomial vs OvR : le verrou de la classe rare

Mêmes équations, comportements différents en $p \gg n$ avec classes déséquilibrées.

SGCCA + LDA / Cooperative OvR

	p.cort	p.dipg	p.midl
v.cort	5	0	0
v.dipg	0	6	0
v.midl	0	1	**2**

bal_acc = 0,924 : midl 2/3

Multinomial Lasso (grouped/ungrouped)

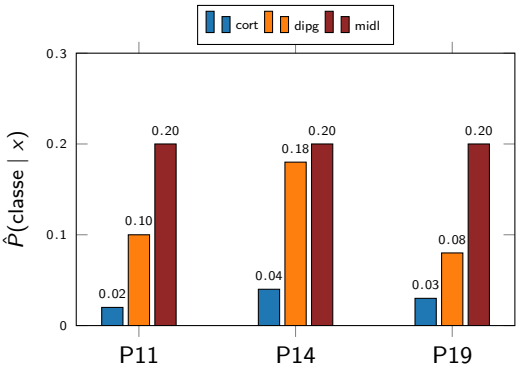
	p.cort	p.dipg	p.midl
v.cort	5	0	0
v.dipg	0	6	0
v.midl	1	2	0

bal_acc = 0,773 : midl 0/3

Le « filet de sauvetage » de l'OvR

En OvR, un classifieur midl-vs-reste à coefficients nuls garde un *intercept* calibré sur la prévalence : $\hat{P}_{\texttt{midl}} \simeq \sigma(\log(8/31)) \simeq 0{,}205$ *constant*. Quand cort et dipg rejettent un patient, ce plancher l'emporte par arg max (p.ex. P11, P19). La contrainte $\sum_c P_c = 1$ du multinomial aspire au contraire cette masse vers dipg.

Repêchage de midl : probabilités prédites (Cooperative OvR)



Pour les 3 vrais `midl` du test, l'OvR prédit un plancher quasi constant

$$\hat{P}_{\texttt{midl}} \simeq \sigma(\log(8/31)) \simeq 0{,}205.$$

`cort` et `dipg` étant rejetés, ce plancher l'emporte par **argmax** (P11, P19).

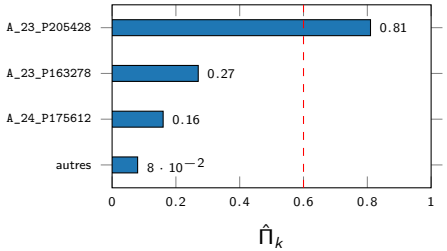
Les multinomiaux, contraints par $\sum_c P_c = 1$, aspirent cette masse vers `dipg` $\Rightarrow$ recall `midl` $= 0/3$.

Plan

1. Introduction et problématique
2. Analyse exploratoire (EDA)
3. Formalisme et méthodes
4. Résultats
5. Stabilité et reproductibilité
6. Travail bibliographique

Stabilité de la sélection de variables

En $p \gg n$, l'identité exacte des variables retenues est instable. On la quantifie par **ré-échantillonnage bootstrap** (Efron, 1979) : fréquence de sélection $\hat{\Pi}_k = \frac{1}{B} \sum_b \mathbf{1}_{\{a_k^{(b)} \neq 0\}}$, « stable set » $= \{k : \hat{\Pi}_k \geq \pi_{\text{thr}}\}$ (Meinshausen & Bühlmann, 2010 ; $\pi_{\text{thr}} = 0{,}6$, $B = 200$).



OvR Lasso : un gène robuste (`A_23_P205428`, $\hat{\Pi} \simeq 0{,}81$).

- un **noyau de gènes GE** est sélectionné de façon stable ;
- **SGCCA** : noyau *plus* stable (3 gènes $> \pi_{\text{thr}}$, même gène de tête que le Lasso $\Rightarrow$ convergence inter-méthodes) ;
- l'**exclusion de CGH** par les méthodes data-driven est *remarquablement stable* : un résultat robuste, non un artefact.

Le signal est-il réel ? Test de permutation

Test de permutation (Ojala & Garriga, 2010) :

- H_0 : aucune dépendance entre variables et étiquettes (BA attendue $= 1/3$) ;
- on *permute* les labels, on ré-entraîne tout le pipeline, $B = 500$ fois ;
- **p-value** = proportion de permutations égalant ou dépassant le score observé.

Résultat

Tous les modèles : **p-value** $= 0{,}002$. On rejette H_0 : le signal prédictif est statistiquement significatif et *non dû au hasard*, malgré $p \gg n$.

Reproductibilité

Graines aléatoires fixées (plis, bootstrap, initialisation des solveurs) $\Rightarrow$ chiffres exactement reproductibles.

Robuste vs fragile

Robuste : signal porté par GE ; CGH non informatif ; `cort`/`dipg` bien séparées ; significativité globale.

Fragile : classement fin des meilleures méthodes ; recall exact sur `midl` (se joue sur 1–2 patients) ; liste précise des gènes (noyau stable, périphérie variable).

Plan

1 Introduction et problématique

2 Analyse exploratoire (EDA)

3 Formalisme et méthodes

4 Résultats

5 Stabilité et reproductibilité

6 Travail bibliographique

Travail bibliographique : fondements et positionnement

Chaque choix méthodologique est ancré dans la littérature :

Intégration multibloc supervisée RGCCA (Tenenhaus & Tenenhaus, *Psychometrika*, 2011) ; SGCCA / sélection de variables (Tenenhaus *et al.*, *Biostatistics*, 2014) ; *block-relaxation* (De Leeuw, 1994 ; Tenenhaus *et al.*, 2017 ; Girka *et al.*, 2024 ; seuil : Gloaguen *et al.*, 2017).

Fusion coopérative Cooperative Learning multi-vues (Ding, Li, Narasimhan & Tibshirani, *PNAS*, 2022).

Régularisation & GLM Lasso / Elastic-Net et descente proximale ; logistique multinomiale (GLM, lien logit) ; pondération `class_weight="balanced"`.

Stabilité & validation Bootstrap (Efron, 1979) ; sélection par stabilité (Meinshausen & Bühlmann, 2010) ; test de permutation (Ojala & Garriga, 2010).

Filiation directe : même jeu de données (gliomes IGR) et même cadre que le *case study* RGCCA ; SGCCA + LDA **reproduit** la cible publiée (CV $\simeq 0{,}826 \pm 0{,}136$, test $\simeq 91{,}7\%$).

Apports : comparaison contrôlée des familles de modèles ; diagnostic de la non-convergence du Cooperative à $\rho > 0$; mécanisme OvR vs multinomial pour `midl` ; analyse de stabilité au-delà de la performance.

Bibliographie complète dans le rapport écrit.

Conclusion

Ce que l'on retient

- **Terrain difficile** : $p \gg n$ + multi-blocs + classe rare `midl` ;
- **SGCCA + LDA** : méthode retenue : la plus performante (test $\simeq 0{,}924$) *et* la plus stable, avec recall `midl` 2/3 ;
- modèle **parcimonieux et interprétable** ($\simeq$ 68 gènes, 11 régions CGH) ;
- signal validé par test de permutation ($p \simeq 0{,}002$).

Perspectives :

- validation sur cohorte externe ; interprétation biologique des gènes stables ;
- plusieurs composantes SGCCA ; intégration d'un 3e bloc (clinique).

Merci de votre attention :)